

Face Detection für Video-Anonymisierung

**Modellvergleich, Evaluation und Blur-Pipeline mit
WIDER FACE**

25. Juni 2026

Milena Witt Clemens Schierack

Fakultät Informatik und Medien
HTWK Leipzig

Gliederung

1. Problem und Projekt
2. Modelle und Evaluation
3. Video-Anonymisierung

Problem und Projekt

Titel und Problem

- Automatische Video-Anonymisierung steht und faellt mit zuverlaessiger Face Detection.
- Gesichter muessen zuerst lokalisiert werden, bevor sie geblurt werden koennen.
- Datenschutzfehler entstehen vor allem durch nicht erkannte Gesichter.
- Deshalb ist Recall wichtiger als eine perfekte, aber zu vorsichtige Detektion.

Leitfrage

Welches Modell findet moeglichst viele Gesichter und bleibt praktisch genug fuer eine Video-Pipeline?

Projektziel

- WIDER FACE wird in ein trainierbares Format fuer Object Detection gebracht.
- Mehrere Detektoren werden trainiert und auf gleicher Datenbasis verglichen.
- Die Bewertung verbindet Recall, Precision, Latenz, Modellgroesse und Trainingsaufwand.
- Das praktikabelste Modell wird in einer Video-Blur-Pipeline eingesetzt.

Pipeline

Datensatz → Annotationen → Training → Evaluation → Video-Anonymisierung

Projektstruktur

<code>datasets/wider_face/</code>	Rohdaten und Splits des WIDER-FACE-Datensatzes.
<code>annotations/</code>	COCO-Annotationen fuer Torchvision-Training und Evaluation.
<code>trained_models/</code>	Trainierte Gewichte und YOLO-Run-Artefakte.
<code>model_results/</code>	CSV/JSON-Ergebnisse, Plots und Trainingshistorien.
<code>Videos/lab_outputs/</code>	Geblurte Videos, Previews und selektive Testlaeufe.

- Die Trennung macht Training, Evaluation und Videoausgabe reproduzierbar.
- Notebooks dokumentieren die Schritte; Skripte kapseln die ausführbaren Laeufe.

Datensatz WIDER FACE

Grün = Scharf | Orange = Leicht unscharf | Rot = Hintergrund
Bild: 29-Students_Schoolkids/29_Students_Schoolkids_Students_Schoolkids_29_865.jpg



- Viele Bilder enthalten mehrere Gesichter.
- Kleine, verdeckte und dicht gruppierte Gesichter sind fuer Datenschutz besonders kritisch.
- Bounding Boxes liefern die Ground Truth fuer Recall und IoU-Matching.
- Die Validierung ist anspruchsvoll, weil einzelne Bilder sehr viele Faces enthalten koennen.

Detection-Grundlagen

Metrik	Bedeutung	Rolle im Projekt
IoU	Ueberlappung von Vorhersagebox und Ground Truth	entscheidet, ob ein Face als gefunden gilt
Confidence	Modell-Sicherheit fuer eine Box	steuert den Score-Threshold
Recall	gefundene Gesichter / alle Gesichter	wichtigste Datenschutzmetrik
Precision	korrekte Boxen / alle Boxen	reduziert unnoetige Blur-Boxen
ms/Bild	Inferenzzeit pro Bild	entscheidend fuer Videos

Bewertung

Uebergang zu den Modellen

- COCO-vortrainierte Objektmodelle erkennen Personen und Objekte, aber nicht automatisch kleine Face-Boxes.
- Darum werden face-spezifisch trainierte Detektoren auf WIDER FACE verglichen.
- Die folgende Modellwahl prueft Qualitaet, Geschwindigkeit und Pipeline-Tauglichkeit gemeinsam.

Uebergabe

Damit ist klar, was gemessen wird und warum Recall zentral ist. Als Naechstes geht es darum, welche Modellfamilien getestet wurden und welches Modell auf gleicher Datenbasis am besten abschneidet.


Modelle und Evaluation

Warum mehrere Modelle?

Modell	Familie	Erwartung
Faster R-CNN	Two-Stage	robuste Lokalisierung, aber mehr Rechenaufwand
RetinaNet	One-Stage mit Focal Loss	schnelle Baseline, gut bei vielen Hintergrundbereichen
FCOS	Anchor-free One-Stage	starker Recall ohne Anchor-

Wie funktionieren die Modelle?

Faster R-CNN	Ein Region Proposal Network schlägt Bereiche vor; danach werden Regionen klassifiziert und Boxen verfeinert.
RetinaNet	Klassifiziert und lokalisiert direkt auf Feature Maps; Focal Loss betont schwierige Beispiele.
FCOS	Anchor-free: sagt Objektpositionen pro Feature-Map-Position ohne vordefinierte Anchor-Boxen voraus.
YOLOv8m	One-Stage-Detector mit optimierter Inferenz, Run-Artefakten und direkter Video-Pipeline-Anbindung.




Training und Ressourcen

Lauf	Modelle	Bilder	Epochen
Red20-Smoke	YOLOv8m, Faster R-CNN, RetinaNet, FCOS	ca. 644	1
Red6-Kandidatenlauf	YOLOv8m, FCOS	2.147	10

Modell	Trainingszeit	Groesse	Trainingshinweis
YOLOv8m red6 ep10	16,1 min	50 MB	Precision 0,839; Recall 0,579; mAP50 0,660 im YOLO-Run
FCOS red6 ep10	ca. 58 min	123 MB	Mean Loss 1,243 → 0,735



13



Evaluation und Metriken

Einstellung	Red20	Red6/10	Recall macht Datenschutzrisiko messbar.
Validierungsbilder	300	500	
GT-Faces	3.443	5.015	Treffer zeigen die absolute Groessenordnung.
IoU-Schwelle	0,4	0,4	
Confidence	0,25	0,25	Precision und F1 helfen bei der Threshold-Wahl.

- ms/Bild entscheidet ueber Videotauglichkeit.



Vergleich aller Modelle




Breiter Smoke-Vergleich	GT-Faces	Treffer	Recall	ms/Bild	
FCOS red20 ep1	3.443	1.884	0,547	36,2	
Faster R-CNN red20 ep1	3.443	1.714	0,498	51,4	
YOLOv8m red20 ep1	3.443	1.399	0,406	43,7	
RetinaNet red20 ep1	3.443	1.125	0,327	35,0	

Red6/10-Favoritenvergleich	GT-Faces	Treffer	Recall	ms/Bild	Interpretation
FCOS red6 ep10	5.015	3.375	0,673	55,7	bester Recall
YOLOv8m red6 ep10	5.015	2.445	0,488	31,2	schneller Pipeline-Kandidat
COCO FCOS	5.015	224	0,045	44,6	nicht face-finetuned
COCO YOLOv8m	5.015	46	0,009	17,3	nicht face-finetuned

- FCOS wird Qualitätsfavorit; YOLOv8m bleibt Praxisfavorit fuer die Video-Pipeline.
- COCO-Baselines zeigen, warum Face-Finetuning notwendig ist.


Vergleichsgrafiken und Thresholds

Evaluationsdashboard: Modellvergleich und Favoritenentscheidung



- Höhere Thresholds reduzieren Fehlalarme.
- Gleichzeitig sinkt der Recall.
- Für Datenschutz ist ein

Bestes Modell und Uebergabe



- FCOS ist der Recall-Sieger und damit die staerkste Wahl fuer maximale Abdeckung.
- YOLOv8m ist schneller, liefert viele Run-Artefakte und passt gut zur Video-Pipeline.
- Die Modellentscheidung ist deshalb zweigeteilt: Qualitaet gegen operative Einfachheit.

Uebergabe


Video-Anonymisierung

Video-Pipeline

1. Video laden und Frames verarbeiten.
2. Optional deinterlacen.
3. Gesichter pro Frame detektieren.
4. Blur-Maske auf erkannte Gesichtsregionen anwenden.
5. Ergebnis in Videos/lab_outputs/ schreiben.

Praxis

Die technische Modellqualitaet wird erst in der Videoausgabe wirklich sichtbar: verpasste Boxen bleiben sichtbare Gesichter.



Selektives Blurring

- Neben "alle Gesichter blurren" gibt es einen Lauf fuer konkrete Zielgesichter.
- Ein Preview-Lauf zeigt Boxen, Raenge und Track-IDs.
- Danach koennen `--target-track-ids`, `--target-ranks` oder `--target-regions` gesetzt werden.
- So lassen sich einzelne Personen gezielt anonymisieren, ohne jedes Gesicht im Bild zu verdecken.

Kontrolle

Selektives Blurring ist praktisch, braucht aber eine visuelle Pruefung der Track-Stabilitaet.

Ergebnisvideo und Blur-Qualitaet

- Ovaler Gaussian Blur wirkt natuerlich und deckt Gesichter weich ab.
- Pixelate ist sichtbarer und kann bei kleinen Gesichtern haerter wirken.
- Die Blur-Qualitaet haengt direkt am Detektions-Recall.
- Smoke-Videos zeigen die Pipeline, ersetzen aber keine finale Datenschutzpruefung.

Qualitaetscheck

Technisch gute Metriken reichen nicht: Am Ende muss das Video visuell auf verpasste Gesichter geprueft werden.

Fazit

- FCOS red6 ep10 erreicht den besten Recall: 0,673 auf 500 Bildern mit 5.015 GT-Faces.
- YOLOv8m red6 ep10 erreicht Recall 0,488, ist aber schneller und pipelinefreundlicher.
- COCO-Baselines fallen klar ab und bestätigen die Notwendigkeit von Face-Finetuning.
- Für Datenschutz zählt zuerst Abdeckung; für die praktische Video-Pipeline zählen zusätzlich Geschwindigkeit und Artefakte.

Quellen