

Face Detection für Video-Anonymisierung

**Modellvergleich, Evaluation und Blur-Pipeline mit
WIDER FACE**

25. Juni 2026

Milena Witt Clemens Schierack

Fakultät Informatik und Medien
HTWK Leipzig

Gliederung

1. Problem und Projekt
2. Modelle und Evaluation
3. Video-Anonymisierung

Problem und Projekt

Titel und Problem

- Video-Anonymisierung benötigt zuverlässige Face Detection
- Gesichter lokalisieren und dann blurren
- Problem nicht erkannter Gesichter (Datenschutz)
→ Recall wichtiger als perfekte Detektion

Leitfrage

Welches Modell findet möglichst viele Gesichter und ist praktisch genug für eine Video-Pipeline?

Projektziel

- Datensatz WIDER FACE wird trainiert
→ Formatanpassung für Object Detection
- Mehrere Algorithmen werden trainiert und auf gleicher Datenbasis verglichen.
- Die Bewertung verbindet Recall, Precision, Latenz, Modellgröße und Trainingsaufwand
- Das praktikabelste Modell wird in einer Video-Blur-Pipeline eingesetzt

Pipeline

Datensatz → Annotationen → Training → Evaluation → Video-Anonymisierung

Projektstruktur

<code>datasets/wider_face/</code>	Rohdaten und Splits des WIDER-FACE-Datensatzes.
<code>annotations/</code>	COCO-Annotationen für Torchvision-Training und Evaluation.
<code>trained_models/</code>	Trainierte Gewichte und YOLO-Run-Artefakte.
<code>model_results/</code>	CSV/JSON-Ergebnisse, Plots und Trainingshistorien.
<code>Videos/lab_outputs/</code>	Geblurrt Videos, Previews und selektive Testläufe.

- Die Trennung macht Training, Evaluation und Videoausgabe reproduzierbar.
- Notebooks dokumentieren die Schritte; Skripte kapseln die ausführbaren Läufe.

Datensatz WIDER FACE

Grün = Scharf | Orange = Leicht unscharf | Rot = Hintergrund
Bild: 29--Students_Schoolkids/29_Students_Schoolkids_Students_Schoolkids_29_865.jpg



- Viele Bilder enthalten mehrere Gesichter.
- Kleine, verdeckte und dicht gruppierte Gesichter
- Bounding Boxes liefern die Ground Truth für Recall und IoU-Matching

Detection-Grundlagen

Metrik	Bedeutung	Rolle im Projekt
IoU	Vorhersagebox und Ground Truth	Gesicht gefunden?
Confidence	Modell-Sicherheit für eine Box	Score-Threshold
Recall	gefundene Gesichter / alle Gesichter	Erfolgsmetrik
Precision	korrekte Boxen / alle Boxen	reduziert unnötige Blur-Boxen
ms/Bild	Inferenzzeit pro Bild	entscheidend für Videos

Bewertung

Für Datenschutz ist ein verpasstes Gesicht kritischer als eine zusätzliche Blur-Box.

Übergang zu den Modellen

- COCO-vortrainierte Objektmodelle erkennen Personen und Objekte, aber nicht automatisch kleine Gesichtsboxen.
- Darum werden face-spezifisch trainierte Detektoren auf WIDER FACE verglichen.
- Die folgende Modellwahl prüft Qualität, Geschwindigkeit und Pipeline-Tauglichkeit gemeinsam.

Übergabe

Damit ist klar, was gemessen wird und warum Recall zentral ist. Als Nächstes geht es darum, welche Modellfamilien getestet wurden und welches Modell auf gleicher Datenbasis am besten abschneidet.

Modelle und Evaluation


Warum mehrere Modelle?

Modell	Familie	Erwartung
Faster R-CNN	Two-Stage	robuste Lokalisierung, aber mehr Rechenaufwand
RetinaNet	One-Stage mit Focal Loss	schnelle Baseline, gut bei vielen Hintergrundbereichen
FCOS	Anchor-free One-Stage	starker Recall ohne Anchor-Tuning
YOLOv8m	praxisoptimierter One-Stage	schnelle Inferenz und einfache Videoanbindung

- Face Detection wird als Object-Detection-Problem formuliert.
- Der Vergleich trennt Qualitätsfavorit und Praxisfavorit.

Wie funktionieren die Modelle?

Faster R-CNN	Ein Region Proposal Network schlägt Bereiche vor; danach werden Regionen klassifiziert und Boxen verfeinert.
RetinaNet	Klassifiziert und lokalisiert direkt auf Feature Maps; Focal Loss betont schwierige Beispiele.
FCOS	Anchor-free: sagt Objektpositionen pro Feature-Map-Position ohne vordefinierte Anchor-Boxen voraus.
YOLOv8m	One-Stage-Detector mit optimierter Inferenz, Run-Artefakten und direkter Video-Pipeline-Anbindung.



Modellfunktion im Ablauf

Schritt	Funktion
Backbone	extrahiert Merkmale aus dem Bild
Feature Maps	bilden Gesichter in mehreren Skalen ab
Head	sagt Klasse, Score und Box voraus
NMS	entfernt doppelte Treffer

- Two-Stage-Modelle prüfen erst Kandidatenregionen.
- One-Stage-Modelle lokalisieren und klassifizieren direkt.
- Anchor-free-Modelle ersetzen vordefinierte Box-Anker durch Punktvorhersagen.

Kernidee

Alle Varianten erzeugen am Ende Bounding Boxes mit Confidence-Werten; sie unterscheiden sich vor allem darin, wie Kandidaten entstehen und wie direkt lokalisiert wird.

Faster R-CNN: Ablauf im Projekt


1. Backbone extrahiert Bildmerkmale.
 2. RPN schlägt mögliche Gesichtsregionen vor.
 3. ROI Head klassifiziert Regionen und verfeinert Boxen.
 4. IoU und Confidence entscheiden über Treffer.
- WIDER FACE wurde in passende Annotationen für Torchvision übertragen.
 - Im Red20-Smoke-Test lief Faster R-CNN gegen YOLOv8m, RetinaNet und FCOS.
 - Ergebnis: guter Recall, aber höhere Latenz als schnellere One-Stage-Ansätze.

Unterschied: Faster R-CNN sucht erst Kandidatenregionen und prüft sie danach genauer. YOLO/RetinaNet lokalisieren direkter; FCOS arbeitet zusätzlich anchor-free.

Training und Ressourcen

Lauf	Modelle	Bilder	Epochen	Batch	GPU
Red20-Smoke	YOLOv8m, Faster R-CNN, RetinaNet, FCOS	ca. 644	1	2	AMD Radeon PRO W7800 48GB
Red6-Kandidatenlauf	YOLOv8m, FCOS	2.147	10	2	AMD Radeon PRO W7800 48GB

Modell	Trainingszeit	Größe	Trainingshinweis
YOLOv8m red6 ep10	16,1 min	50 MB	Precision 0,839; Recall 0,579; mAP50 0,660 im YOLO-Run
FCOS red6 ep10	ca. 58 min	123 MB	Mean Loss 1,243 → 0,735




TODO Rohdaten: CSV/JSON-Trainingshistorien

für YOLO und FCOS ergänzen; erst danach Vergleichsgrafik neu plotten.

Evaluation und Metriken


Einstellung	Red20	Red6/10
Validierungsbilder	300	500
GT-Faces	3.443	5.015
IoU-Schwelle	0,4	0,4
Confidence	0,25	0,25

- Recall macht Datenschutzrisiko messbar.
- Treffer zeigen die absolute Größenordnung.
- Precision und F1 helfen bei der Threshold-Wahl.
- ms/Bild entscheidet über Videotauglichkeit.





Vergleichsgrafiken: Dashboard

Evaluationsdashboard: Modellvergleich und Favoritenentscheidung



- Dashboard: Recall, Treffer, Latenz und Baselines; FCOS dominiert beim Recall, YOLOv8m bleibt der praktischere Video-Kandidat.

Recall und Thresholds



- Höhere Thresholds reduzieren Fehlalarme; gleichzeitig sinkt der Recall.
- Für Datenschutz ist ein niedrigerer Threshold plausibel, weil übersehene Gesichter kritischer sind.


Vergleich aller Modelle

Breiter Smoke-Vergleich	GT-Faces	Treffer	Recall	ms/Bild	
FCOS red20 ep1	3.443	1.884	0,547	36,2	
Faster R-CNN red20 ep1	3.443	1.714	0,498	51,4	
YOLOv8m red20 ep1	3.443	1.399	0,406	43,7	
RetinaNet red20 ep1	3.443	1.125	0,327	35,0	

Red6/10-Favoritenvergleich	GT-Faces	Treffer	Recall	ms/Bild	Interpretation
FCOS red6 ep10	5.015	3.375	0,673	55,7	bester Recall
YOLOv8m red6 ep10	5.015	2.445	0,488	31,2	schneller Pipeline-Kandidat
COCO FCOS	5.015	224	0,045	44,6	nicht face-finetuned
COCO YOLOv8m	5.015	46	0,009	17,3	nicht face-finetuned

- FCOS wird Qualitätsfavorit; YOLOv8m bleibt Praxisfavorit für die Video-Pipeline.
- COCO-Baselines zeigen, warum Face-Finetuning notwendig ist.

Bestes Modell und Übergabe



- FCOS ist der Recall-Sieger und damit die stärkste Wahl für maximale Abdeckung.
- YOLOv8m ist schneller, liefert viele Run-Artefakte und passt gut zur Video-Pipeline.
- Die Modellentscheidung ist deshalb zweigeteilt: Qualität gegen operative Einfachheit.

Übergabe

Jetzt schauen wir, wie aus der Detektion geblurrte Videos entstehen.


Video-Anonymisierung

Video-Pipeline

1. Video laden und Frames verarbeiten.
2. Optional deinterlacen.
3. Gesichter pro Frame detektieren.
4. Blur-Maske auf erkannte Gesichtsregionen anwenden.
5. Ergebnis in Videos/lab_outputs/ schreiben.

Praxis

Die technische Modellqualität wird erst in der Videoausgabe wirklich sichtbar: verpasste Boxen bleiben sichtbare Gesichter.



Selektives Blurring

- Neben “alle Gesichter blurren” gibt es einen Lauf für konkrete Zielgesichter.
- Ein Preview-Lauf zeigt Boxen, Ränge und Track-IDs.
- Danach können `--target-track-ids`, `--target-ranks` oder `--target-regions` gesetzt werden.
- So lassen sich einzelne Personen gezielt anonymisieren, ohne jedes Gesicht im Bild zu verdecken.

Kontrolle

Selektives Blurring ist praktisch, braucht aber eine visuelle Prüfung der Track-Stabilität.


Ergebnisvideo und Blur-Qualität

- Ovaler Gaussian Blur wirkt natürlich und deckt Gesichter weich ab.
- Pixelate ist sichtbarer und kann bei kleinen Gesichtern härter wirken.
- Die Blur-Qualität hängt direkt am Detektions-Recall.
- Smoke-Videos zeigen die Pipeline, ersetzen aber keine finale Datenschutzprüfung.

Qualitätscheck

Technisch gute Metriken reichen nicht: Am Ende muss das Video visuell auf verpasste Gesichter geprüft werden.

Fazit: Modellqualität



- FCOS red6 ep10 erreicht den besten Recall: 0,673 auf 500 Bildern mit 5.015 GT-Faces.
- COCO-Baselines fallen klar ab und bestätigen die Notwendigkeit von Face-Finetuning.

Fazit: Pipeline-Entscheidung



- YOLOv8m red6 ep10 erreicht Recall 0,488, ist aber schneller und pipelinefreundlicher.
- Für Datenschutz zählt zuerst Abdeckung; für die praktische Video-Pipeline zählen zusätzlich Geschwindigkeit und Artefakte.

Quellen