

Face Detection für Video-Anonymisierung

**Modellvergleich, Evaluation und Blur-Pipeline mit
WIDER FACE**

25. Juni 2026

Milena Witt Clemens Schierack

Fakultät Informatik und Medien
HTWK Leipzig

Gliederung

1. Problem und Projekt
2. Modelle und Evaluation
3. Video-Anonymisierung

Problem und Projekt

Titel und Problem

- Video-Anonymisierung benötigt zuverlässige Face Detection
- Gesichter lokalisieren und dann blurren
- Problem nicht erkannter Gesichter (Datenschutz)
→ Recall wichtiger als perfekte Detektion

Leitfrage

Welches Modell findet möglichst viele Gesichter und ist praktisch genug für eine Video-Pipeline?

Projektziel

- Datensatz WIDER FACE wird trainiert
→ Formatanpassung für Object Detection
- Mehrere Algorithmen werden trainiert und auf gleicher Datenbasis verglichen.
- Die Bewertung verbindet Recall, Precision, Latenz, Modellgröße und Trainingsaufwand
- Das praktikabelste Modell wird in einer Video-Blur-Pipeline eingesetzt

Pipeline

Datensatz → Annotationen → Training → Evaluation → Video-Anonymisierung

Projektstruktur

<code>datasets/wider_face/</code>	Rohdaten und Splits des WIDER-FACE-Datensatzes aus Kaggle. [2]
<code>annotations/</code>	COCO-Annotationen für Torchvision-Training und Evaluation.
<code>trained_models/</code>	Trainierte Gewichte und YOLO-Run-Artefakte.
<code>model_results/</code>	CSV/JSON-Ergebnisse, Plots und Trainingshistorien.
<code>Videos/lab_outputs/</code>	Geblurrt Videos, Previews und selektive Testläufe.

- Die Trennung macht Training, Evaluation und Videoausgabe reproduzierbar.
- Notebooks dokumentieren die Schritte; Skripte kapseln die ausführbaren Läufe.

Datensatz WIDER FACE

Grün = Scharf | Orange = Leicht unscharf | Rot = Hintergrund
Bild: 29-Students_Schoolkids/29_Students_Schoolkids_Students_Schoolkids_29_865.jpg



- Viele Bilder enthalten mehrere Gesichter.
- Kleine, verdeckte und dicht gruppierte Gesichter
- Bounding Boxes liefern die Ground Truth für Recall und IoU-Matching

Quellen: WIDER FACE Benchmark [5]; Kaggle-Datensatz [2]

Detection-Grundlagen

Metrik	Bedeutung	Rolle im Projekt
IoU	Vorhersagebox und Ground Truth	Gesicht gefunden?
Confidence	Modell-Sicherheit für eine Box	Score-Threshold
Recall	gefundene Gesichter / alle Gesichter	Erfolgsmetrik
Precision	korrekte Boxen / alle Boxen	reduziert unnötige Blur-Boxen
ms/Bild	Inferenzzeit pro Bild	entscheidend für Videos

Bewertung

Für Datenschutz ist ein verpasstes Gesicht kritischer als eine zusätzliche Blur-Box.

Übergang zu den Modellen

- COCO-vortrainierte Objektmodelle erkennen Personen und Objekte, aber nicht automatisch kleine Gesichtsboxen.
- Darum werden face-spezifisch trainierte Detektoren auf WIDER FACE verglichen.
- Die folgende Modellwahl prüft Qualität, Geschwindigkeit und Pipeline-Tauglichkeit gemeinsam.

Übergabe

Damit ist klar, was gemessen wird und warum Recall zentral ist. Als Nächstes geht es darum, welche Modellfamilien getestet wurden und welches Modell auf gleicher Datenbasis am besten abschneidet.

Modelle und Evaluation


Warum mehrere Modelle?

Modell	Familie	Erwartung
Faster R-CNN [3]	Two-Stage	robuste Lokalisierung, aber mehr Rechenaufwand
RetinaNet [1]	One-Stage mit Focal Loss	schnelle Baseline, gut bei vielen Hintergrundbereichen
FCOS [4]	Anchor-free One-Stage	starker Recall ohne Anchor-Tuning
YOLOv8m [6]	praxisoptimierter One-Stage	schnelle Inferenz und einfache Videoanbindung

- Face Detection wird als Object-Detection-Problem formuliert.
- Der Vergleich trennt Qualitätsfavorit und Praxisfavorit.

Wie funktionieren die Modelle?

Modell	Prinzip	Stärke
Faster R-CNN [3]	erst Vorschläge, dann Prüfung	robuste Boxen
RetinaNet [1]	direkte Vorhersage mit Focal Loss	schwierige Beispiele
FCOS [4]	direkte Vorhersage ohne Anchor	hoher Recall
YOLOv8m [6]	direkte, optimierte Vorhersage	Video-Pipeline



Faster R-CNN

1. Backbone extrahiert Merkmale.
 2. RPN schlägt Face-Regionen vor.
 3. ROI Head prüft Kandidaten.
 4. Boxen werden verfeinert.
- Two-Stage-Referenzmodell.
 - Gut für robuste Lokalisierung.
 - Mehr Rechenaufwand pro Bild.
 - Im Projekt solide, aber nicht Favorit.

Kernidee

Erst mögliche Gesichter suchen, danach genauer klassifizieren.

RetinaNet

- One-Stage-Detector.
- Direkte Box- und Klassenprognose.
- Anchor-Boxen in mehreren Grössen.
- Focal Loss für schwierige Beispiele.

Warum Focal Loss?

Viele Bildbereiche sind Hintergrund. Focal Loss reduziert einfache Negativbeispiele und betont harte Fälle.

Projektbefund: schnell, aber niedrigster Recall der trainierten Modelle.

FCOS

- One-Stage, aber anchor-free.
- Keine vordefinierten Box-Anker.
- Positionen sagen Box-Ränder voraus.
- Weniger Anchor-Tuning nötig.

Projektbefund

FCOS findet die meisten Ground-Truth-Gesichter und ist damit der Recall-Sieger.

Trade-off: hoher Recall, aber langsamere Inferenz als YOLOv8m.

YOLOv8m

- One-Stage-Detector.
- Direkte Boxen und Confidence pro Frame.
- Optimiert für schnelle Inferenz.
- Gute Integration in Video-Workflows.

Projektbefund


YOLO ist nicht der Recall-Sieger, aber am besten für Preview, Tracking und Blur-Pipeline angebunden.

Stärke: Trainingsplots, PR-Kurven und einfache Videoanbindung über Ultralytics.

Training und Ressourcen

Lauf	Modelle	Bilder	Epochen	Batch	GPU
Red20-Smoke	YOLOv8m, Faster R-CNN, RetinaNet, FCOS	ca. 644	1	2	AMD Radeon PRO W7800 48GB
Red6-Kandidatenlauf	YOLOv8m, FCOS	2.147	10	2	AMD Radeon PRO W7800 48GB

Modell	Trainingszeit	Größe	Trainingshinweis
YOLOv8m red6 ep10	16,1 min	50 MB	Precision 0,839; Recall 0,579; mAP50 0,660 im YOLO-Run
FCOS red6 ep10	ca. 58 min	123 MB	Mean Loss 1,243 → 0,735




TODO Rohdaten: CSV/JSON-Trainingshistorien

für YOLO und FCOS ergänzen; erst danach Vergleichsgrafik neu plotten.

Evaluation und Metriken


Einstellung	Red20	Red6/10
Validierungsbilder	300	500
GT-Faces	3.443	5.015
IoU-Schwelle	0,4	0,4
Confidence	0,25	0,25

- Recall macht Datenschutzrisiko messbar.
- Treffer zeigen die absolute Größenordnung.
- Precision und F1 helfen bei der Threshold-Wahl.
- ms/Bild entscheidet über Videotauglichkeit.





Vergleichsgrafiken: Dashboard

Evaluationsdashboard: Modellvergleich und Favoritenentscheidung



- Dashboard: Recall, Treffer, Latenz und Baselines; FCOS dominiert beim Recall, YOLOv8m bleibt der praktischere Video-Kandidat.

Recall und Thresholds



- Höhere Thresholds reduzieren Fehlalarme; gleichzeitig sinkt der Recall.
- Für Datenschutz ist ein niedrigerer Threshold plausibel, weil übersehene Gesichter kritischer sind.


Vergleich aller Modelle

Breiter Smoke-Vergleich	GT-Faces	Treffer	Recall	ms/Bild	
FCOS red20 ep1	3.443	1.884	0,547	36,2	
Faster R-CNN red20 ep1	3.443	1.714	0,498	51,4	
YOLOv8m red20 ep1	3.443	1.399	0,406	43,7	
RetinaNet red20 ep1	3.443	1.125	0,327	35,0	

Red6/10-Favoritenvergleich	GT-Faces	Treffer	Recall	ms/Bild	Interpretation
FCOS red6 ep10	5.015	3.375	0,673	55,7	bester Recall
YOLOv8m red6 ep10	5.015	2.445	0,488	31,2	schneller Pipeline-Kandidat
COCO FCOS	5.015	224	0,045	44,6	nicht face-finetuned
COCO YOLOv8m	5.015	46	0,009	17,3	nicht face-finetuned

- FCOS wird Qualitätsfavorit; YOLOv8m bleibt Praxisfavorit für die Video-Pipeline.
- COCO-Baselines zeigen, warum Face-Finetuning notwendig ist.

Bestes Modell und Übergabe



- FCOS ist der Recall-Sieger und damit die stärkste Wahl für maximale Abdeckung.
- YOLOv8m ist schneller, liefert viele Run-Artefakte und passt gut zur Video-Pipeline.
- Die Modellentscheidung ist deshalb zweigeteilt: Qualität gegen operative Einfachheit.

Übergabe

Video-Übergang: erst ungeblurrtes Original, dann dieselbe Szene mit unterschiedlichen Modellen oder Blur-Stärken. So werden Recall, Box-Grösse und Blur-Qualität sichtbar.


Video-Anonymisierung

Video-Pipeline

1. Video laden und Frames verarbeiten.
2. Optional deinterlacen.
3. Gesichter pro Frame detektieren.
4. Blur-Maske auf erkannte Gesichtsregionen anwenden.
5. Ergebnis in Videos/lab_outputs/ schreiben.

Praxis

Die technische Modellqualität wird erst in der Videoausgabe wirklich sichtbar: verpasste Boxen bleiben sichtbare Gesichter.



matik und Medien
eipzig

Selektives Blurring

- Neben “alle Gesichter blurren” gibt es einen Lauf für konkrete Zielgesichter.
- Ein Preview-Lauf zeigt Boxen, Ränge und Track-IDs.
- Danach können `--target-track-ids`, `--target-ranks` oder `--target-regions` gesetzt werden.
- So lassen sich einzelne Personen gezielt anonymisieren, ohne jedes Gesicht im Bild zu verdecken.

Kontrolle

Selektives Blurring ist praktisch, braucht aber eine visuelle Prüfung der Track-Stabilität.


Ergebnisvideo und Blur-Qualität

- Ovaler Gaussian Blur wirkt natürlich und deckt Gesichter weich ab.
- Pixelate ist sichtbarer und kann bei kleinen Gesichtern härter wirken.
- Die Blur-Qualität hängt direkt am Detektions-Recall.
- Smoke-Videos zeigen die Pipeline, ersetzen aber keine finale Datenschutzprüfung.

Qualitätscheck


Technisch gute Metriken reichen nicht: Am Ende muss das Video visuell auf verpasste Gesichter geprüft werden.

Fazit: Modellqualität



- FCOS red6 ep10 erreicht den besten Recall: 0,673 auf 500 Bildern mit 5.015 GT-Faces.
- COCO-Baselines fallen klar ab und bestätigen die Notwendigkeit von Face-Finetuning.

Fazit: Pipeline-Entscheidung



- YOLOv8m red6 ep10 erreicht Recall 0,488, ist aber schneller und pipelinefreundlicher.
- Für Datenschutz zählt zuerst Abdeckung; für die praktische Video-Pipeline zählen zusätzlich Geschwindigkeit und Artefakte.

Quellen

- [1] Tsung-Yi Lin et al. "Focal Loss for Dense Object Detection". In: *arXiv preprint arXiv:1708.02002* (2017).
- [2] mksaad. *WIDER FACE: A Face Detection Benchmark Dataset on Kaggle*. Kaggle dataset: <https://www.kaggle.com/datasets/mksaad/wider-face-a-face-detection-benchmark>. Kaggle. 2020. URL: <https://www.kaggle.com/datasets/mksaad/wider-face-a-face-detection-benchmark> (visited on 06/25/2026).
- [3] Shaoqing Ren et al. "Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks". In: *arXiv preprint arXiv:1506.01497* (2015).
- [4] Zhi Tian et al. "FCOS: Fully Convolutional One-Stage Object Detection". In: *arXiv preprint arXiv:1904.01355* (2019).
- [5] Shuo Yang et al. "WIDER FACE: A Face Detection Benchmark". In: *arXiv preprint arXiv:1511.06523* (2015).
- [6] Muhammad Yaseen. "What is YOLOv8: An In-Depth Exploration of the Internal Features of the Next-Generation Object Detector". In: *arXiv preprint arXiv:2408.15857* (2024).