

Face Detection für Video-Anonymisierung

**Modellvergleich, Evaluation und Blur-Pipeline mit
WIDER FACE**

25. Juni 2026

Milena Witt

Clemens Schierack

Fakultät Informatik und Medien
HTWK Leipzig

Gliederung

1. Problem und Projekt
2. Modelle und Evaluation
3. Video-Anonymisierung

Problem und Projekt

Titel und Problem

- Video-Anonymisierung benötigt zuverlässige Face Detection
- Gesichter lokalisieren und dann blurren
- Problem nicht erkannter Gesichter (Datenschutz)
→ Recall wichtiger als perfekte Detektion

Leitfrage

Welches Modell findet möglichst viele Gesichter und ist praktisch genug für eine Video-Pipeline?

Projektziel

- Datensatz WIDER FACE wird trainiert
→ Formatanpassung für Object Detection
- Mehrere Algorithmen werden trainiert und auf gleicher Datenbasis verglichen.
- Die Bewertung verbindet Recall, Precision, Latenz, Modellgröße und Trainingsaufwand
- Das praktikabelste Modell wird in einer Video-Blur-Pipeline eingesetzt

Pipeline

Datensatz → Annotationen → Training → Evaluation → Video-Anonymisierung

Projektstruktur

<code>datasets/wider_face/</code>	Rohdaten und Splits des WIDER-FACE-Datensatzes aus Kaggle. [2]
<code>annotations/</code>	COCO-Annotationen für Torchvision-Training und Evaluation.
<code>trained_models/</code>	Trainierte Gewichte und YOLO-Run-Artefakte.
<code>model_results/</code>	CSV/JSON-Ergebnisse, Plots und Trainingshistorien.
<code>Videos/lab_outputs/</code>	Geblurrt Videos, Previews und selektive Testläufe.

- Die Trennung macht Training, Evaluation und Videoausgabe reproduzierbar.
- Notebooks dokumentieren die Schritte; Skripte kapseln die ausführbaren Läufe.

Datensatz WIDER FACE

Grün = Scharf | Orange = Leicht unscharf | Rot = Hintergrund
Bild: 29-Students_Schoolkids/29_Students_Schoolkids_Students_Schoolkids_29_865.jpg



- Viele Bilder enthalten mehrere Gesichter.
- Kleine, verdeckte und dicht gruppierte Gesichter
- Bounding Boxes liefern die Ground Truth für Recall und IoU-Matching

Quellen: WIDER FACE Benchmark [5]; Kaggle-Datensatz [2]

Detection-Grundlagen

Metrik	Bedeutung	Rolle im Projekt
IoU	Vorhersagebox und Ground Truth	Gesicht gefunden?
Confidence	Modell-Sicherheit für eine Box	Score-Threshold
Recall	gefundene Gesichter / alle Gesichter	Erfolgsmetrik
Precision	korrekte Boxen / alle Boxen	reduziert unnötige Blur-Boxen
ms/Bild	Inferenzzeit pro Bild	entscheidend für Videos

Bewertung

Für Datenschutz ist ein verpasstes Gesicht kritischer als eine zusätzliche Blur-Box.

Übergang zu den Modellen

- COCO-vortrainierte Objektmodelle erkennen Personen und Objekte, aber nicht automatisch kleine Gesichtsboxen.
- Darum werden face-spezifisch trainierte Detektoren auf WIDER FACE verglichen.
- Die folgende Modellwahl prüft Qualität, Geschwindigkeit und Pipeline-Tauglichkeit gemeinsam.

Übergabe

Damit ist klar, was gemessen wird und warum Recall zentral ist. Als Nächstes geht es darum, welche Modellfamilien getestet wurden und welches Modell auf gleicher Datenbasis am besten abschneidet.

Modelle und Evaluation


Warum mehrere Modelle?

Modell	Familie	Erwartung
Faster R-CNN [3]	Two-Stage	robuste Lokalisierung, aber mehr Rechenaufwand
RetinaNet [1]	One-Stage mit Focal Loss	schnelle Baseline, gut bei vielen Hintergrundbereichen
FCOS [4]	Anchor-free One-Stage	starker Recall ohne Anchor-Tuning
YOLOv8m [6]	praxisoptimierter One-Stage	schnelle Inferenz und einfache Videoanbindung

- Face Detection wird als Object-Detection-Problem formuliert.
- Der Vergleich trennt Qualitätsfavorit und Praxisfavorit.

Wie funktionieren die Modelle?

Modell	Prinzip	Stärke
Faster R-CNN [3]	erst Vorschläge, dann Prüfung	robuste Boxen
RetinaNet [1]	direkte Vorhersage mit Focal Loss	schwierige Beispiele
FCOS [4]	direkte Vorhersage ohne Anchor	hoher Recall
YOLOv8m [6]	direkte, optimierte Vorhersage	Video-Pipeline



Faster R-CNN

1. Backbone extrahiert Merkmale.
 2. RPN schlägt Face-Regionen vor.
 3. ROI Head prüft Kandidaten.
 4. Boxen werden verfeinert.
- Two-Stage-Referenzmodell.
 - Gut für robuste Lokalisierung.
 - Mehr Rechenaufwand pro Bild.
 - Im Projekt solide, aber nicht Favorit.

Kernidee

Erst mögliche Gesichter suchen, danach genauer klassifizieren.

RetinaNet

- One-Stage-Detector.
- Direkte Box- und Klassenprognose.
- Anchor-Boxen in mehreren Grössen.
- Focal Loss für schwierige Beispiele.

Warum Focal Loss?

Viele Bildbereiche sind Hintergrund. Focal Loss reduziert einfache Negativbeispiele und betont harte Fälle.

Projektbefund: schnell, aber niedrigster Recall der trainierten Modelle.

FCOS

- One-Stage, aber anchor-free.
- Keine vordefinierten Box-Anker.
- Positionen sagen Box-Ränder voraus.
- Weniger Anchor-Tuning nötig.

Projektbefund

FCOS findet die meisten Ground-Truth-Gesichter und ist damit der Recall-Sieger.

Trade-off: hoher Recall, aber langsamere Inferenz als YOLOv8m.

YOLOv8m

- One-Stage-Detector.
- Direkte Boxen und Confidence pro Frame.
- Optimiert für schnelle Inferenz.
- Gute Integration in Video-Workflows.

Projektbefund


YOLO ist nicht der Recall-Sieger, aber am besten für Preview, Tracking und Blur-Pipeline angebunden.

Stärke: Trainingsplots, PR-Kurven und einfache Videoanbindung über Ultralytics.

Training und Ressourcen

Lauf	Modelle	Bilder	Epochen	Batch	GPU
Red20-Smoke	YOLOv8m, Faster R-CNN, RetinaNet, FCOS	ca. 644	1	2	AMD Radeon PRO W7800 48GB
Red6-Finallauf	YOLOv8m, FCOS	2.147	10	2	AMD Radeon PRO W7800 48GB
RCNN-Guardlauf	Faster R-CNN MobileNetV3-FPN	644	1	2	AMD Radeon PRO W7800 48GB

Modell	Trainingszeit	Größe	Trainingshinweis
YOLOv8m red6 ep10	16,1 min	50 MB	Precision 0,839; Recall 0,579; mAP50 0,660 im YOLO-Run
FCOS red6 ep10	ca. 58 min	123 MB	Mean Loss 1,243 → 0,735
Faster R-CNN	12,9 min	73 MB	105 °C-/8h-Guard, max.
MobileNetV3 red20 ep1			88 °C Junction



Rohdaten: Trainingshistorien und YOLO-Results

Faster R-CNN: Effizienz und Grenzen

105-Grad-/8h-Lauf

- Guard: max. 105 °C
Junction/Edge, max. 8 Stunden.
- Backbone:
MobileNetV3-Large-FPN statt
ResNet50-FPN.
- batch=2, 256/384, workers=2.
- Red10/10 waere zu lang: >9
Stunden pro Epoche.
- Ausgefuehrt: Red20/1, 644 Bilder,
322 Batches.

Gemessene Grenzen

- ResNet50 ohne Resize: unter
100 °C, aber viel zu langsam.
- MobileNet ohne Resize: 100 °C
Junction, Guard-Abbruch.
- MobileNetV3-FPN Red20/1: 12:56
Minuten, max. 88 °C Junction.
- Ergebnis: 0,365 Recall, 620,6
ms/Bild.


Einordnung

Der 105 °C-/8h-Guard war moeglich und wurde nicht ausgereizt. MobileNetV3-FPN macht Training kuehl, verliert aber Validierungsqualitaet und bleibt in der Inferenz langsam.

Evaluation und Metriken



Einstellung	Red20	Red6/10
Validierungsbilder	300	500
GT-Faces	3.443	5.015
IoU-Schwelle	0,4	0,4
Confidence	0,25	0,25

- Recall macht Datenschutzrisiko messbar.
- Treffer zeigen die absolute Größenordnung.
- Precision und F1 helfen bei der Threshold-Wahl.
- ms/Bild entscheidet über Videotauglichkeit.



Vergleich aller Modelle: Red20-Vorauswahl

Modell	GT-Faces	Treffer	Recall	ms/Bild	Rolle nach Vorauswahl
FCOS red20 ep1	3.443	1.884	0,547	36,2	Recall-Gewinner
Faster R-CNN red20 ep1	3.443	1.714	0,498	51,4	starker dritter Kandidat
YOLOv8m red20 ep1	3.443	1.399	0,406	43,7	Pipeline-Gewinner
RetinaNet red20 ep1	3.443	1.125	0,327	35,0	faellt wegen Recall ab



- Erster Block: alle Modelle auf gleicher reduzierter Trainingsbasis.
- Gewinner fuer den vertieften Lauf: FCOS als Recall-Sieger, YOLOv8m als Pipeline-Sieger.
- Faster R-CNN wird zusaetzlich in den finalen Vergleich aufgenommen, weil der


Finaler Vergleich: Gewinner plus neuer RCNN-Lauf

Modell	GT-Faces	Treffer	Recall	ms/Bild	Interpretation
FCOS ResNet50-FPN red6 ep10	5.015	3.375	0,673	34,9	bester Recall schnellster Pipeline- Kandidat kuehler, aber schwach und langsam
YOLOv8m red6 ep10	5.015	2.283	0,455	14,6	
Faster R-CNN MobileNetV3-FPN red20 ep1	5.015	1.829	0,365	620,6	

- Evaluation: 500 Validierungsbilder, 5.015 Ground-Truth-Gesichter, IoU 0,4, Confidence 0,25.
- Der neue RCNN-Lauf nutzt **MobileNetV3-Large-FPN** als Backbone, nicht ResNet50-FPN.
- Der 8h/105 °C-Guard war machbar; die eigentliche Grenze bleibt die geringe RCNN-Effizienz.

Vergleichsgrafiken: Dashboard

Evaluationsdashboard: Modellvergleich und Favoritenentscheidung





Entscheidung:
FCOS = Qualitätssieger
Recall 0.673, aber langsamer

YOLOv8m = Praxisieger
schneller, kleiner, beste Video-Pipeline

Nicht-Favoriten:
Faster R-CNN langsamer als FCOS
RetinaNet niedrigster Recall


- Dashboard: Recall, Treffer, Latenz und Baselines; der finale Dreiervergleich nutzt YOLOv8m/FCOS Red6 und den neuen Faster-R-CNN-MobileNetV3-FPN-Lauf.

Recall und Thresholds




- FCOS bleibt Recall-Sieger; YOLOv8m liegt vor dem neuen Faster-R-CNN-MobileNet-Lauf.
- Der Threshold-Sweep vergleicht FCOS und Faster R-CNN direkt aus den CSV/JSON-Daten.
- RCNN-MobileNet: bei 0,25 nur 0,365 Recall; bei 0,70 steigt Precision auf 0,867, aber Recall faellt auf 0,233.

Latenz im Finalvergleich



- YOLOv8m ist in dieser Evaluation der schnellste Pipeline-Kandidat.
- FCOS ist etwas langsamer, liefert aber mit Abstand den besten Recall.
- Faster R-CNN MobileNetV3-FPN ist trotz leichtem Backbone mit 620,6 ms/Bild nicht video-praktisch.

Gewinner und Übergabe



- FCOS ist der Recall-Sieger im finalen Vergleich.
- YOLOv8m bleibt der schnellste und praktischste Kandidat fuer die Video-Pipeline.
- Faster R-CNN MobileNetV3-FPN bleibt kuehl, erreicht aber nur 0,365 Recall und 620,6 ms/Bild.

Übergabe

Übergabe: Für maximalen Datenschutz-Recall ist FCOS die stärkste Wahl. YOLOv8m bleibt für die Video-Anonymisierung wichtig, weil Pipeline, Tracking und Blur-Artefakte dort bereits direkt sichtbar sind. Faster R-CNN zeigt trotz MobileNetV3-Backbone die Effizienzgrenze der Two-Stage-Familie.


Video-Anonymisierung

Video-Pipeline

1. Video laden und Frames verarbeiten.
2. Optional deinterlacen.
3. Gesichter pro Frame detektieren.
4. Blur-Maske auf erkannte Gesichtsregionen anwenden.
5. Ergebnis in Videos/lab_outputs/ schreiben.

Praxis

Die technische Modellqualität wird erst in der Videoausgabe wirklich sichtbar: verpasste Boxen bleiben sichtbare Gesichter.



matik und Medien
eipzig

Selektives Blurring

- Neben “alle Gesichter blurren” gibt es einen Lauf für konkrete Zielgesichter.
- Ein Preview-Lauf zeigt Boxen, Ränge und Track-IDs.
- Danach können `--target-track-ids`, `--target-ranks` oder `--target-regions` gesetzt werden.
- So lassen sich einzelne Personen gezielt anonymisieren, ohne jedes Gesicht im Bild zu verdecken.

Kontrolle

Selektives Blurring ist praktisch, braucht aber eine visuelle Prüfung der Track-Stabilität.



Ergebnisvideo und Blur-Qualität

- Ovaler Gaussian Blur wirkt natürlich und deckt Gesichter weich ab.
- Pixelate ist sichtbarer und kann bei kleinen Gesichtern härter wirken.
- Die Blur-Qualität hängt direkt am Detektions-Recall.
- Smoke-Videos zeigen die Pipeline, ersetzen aber keine finale Datenschutzprüfung.

Qualitätscheck


Technisch gute Metriken reichen nicht: Am Ende muss das Video visuell auf verpasste Gesichter geprüft werden.

Fazit: Training und Validierung



- Links: Mean Loss aus den Trainings-/Results-CSV-Dateien fuer YOLOv8m, FCOS und Faster R-CNN.
- Rechts: Validierungsmetriken aus der Evaluation; Recall bleibt die wichtigste Datenschutzmetrik.
- Neuer RCNN-Lauf: MobileNetV3-Large-FPN, Red20/1, 12:56 Minuten Training, max. 88 °C Junction.

Fazit: Pipeline-Entscheidung



- FCOS ist Recall-Sieger; YOLOv8m ist schnellster Pipeline-Kandidat.
- Faster R-CNN MobileNetV3-FPN trainiert kuehl, verliert aber Recall und Inferenztempo.
- Entscheidung: FCOS fuer maximale Abdeckung, YOLOv8m fuer die vorhandene Video-Blur-Pipeline.

Quellen

- [1] Tsung-Yi Lin et al. "Focal Loss for Dense Object Detection". In: *arXiv preprint arXiv:1708.02002* (2017).
- [2] mksaad. *WIDER FACE: A Face Detection Benchmark Dataset on Kaggle*. Kaggle dataset: <https://www.kaggle.com/datasets/mksaad/wider-face-a-face-detection-benchmark>. Kaggle. 2020. URL: <https://www.kaggle.com/datasets/mksaad/wider-face-a-face-detection-benchmark> (visited on 06/25/2026).
- [3] Shaoqing Ren et al. "Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks". In: *arXiv preprint arXiv:1506.01497* (2015).
- [4] Zhi Tian et al. "FCOS: Fully Convolutional One-Stage Object Detection". In: *arXiv preprint arXiv:1904.01355* (2019).
- [5] Shuo Yang et al. "WIDER FACE: A Face Detection Benchmark". In: *arXiv preprint arXiv:1511.06523* (2015).
- [6] Muhammad Yaseen. "What is YOLOv8: An In-Depth Exploration of the Internal Features of the Next-Generation Object Detector". In: *arXiv preprint arXiv:2408.15857* (2024).