

Face Detection für Video-Anonymisierung

**Modellvergleich, Evaluation und Blur-Pipeline mit
WIDER FACE**

25. Juni 2026

Milena Witt Clemens Schierack

Fakultät Informatik und Medien
HTWK Leipzig

Gliederung

1. Problem und Projekt
2. Modelle und Training
3. Evaluation
4. Video-Anonymisierung

Problem und Projekt


Titel und Problem

- Sichere Face Detection
- Boxen dann Blur
- Recall vor Perfektion

Projektziel

- WIDER FACE nutzen
- Formate konvertieren
- Modelle vergleichen
- Video-Blur testen

Projektpipeline



Quelle Datensatz: WIDER FACE via Kaggle [2]

Datensatz WIDER FACE



- Viele Gesichter
- Klein und verdeckt
- Boxen als Ground Truth

Quellen: WIDER FACE Benchmark [5]; Kaggle-Datensatz [2]

Detection-Grundlagen

Metrik	Bedeutung	Rolle im Projekt
IoU	Box-Overlap	Treffer?
Confidence	Score	Threshold
Recall	Gefunden/alle	Datenschutz
Precision	Korrekt/alle	Fehlblur
ms/Bild	Inferenzzeit	Video

Übergang zu den Modellen

- COCO reicht nicht.
- Facespezifisch trainieren.
- Erst Training, dann Evaluation.

Modelle und Training

R-CNN-Varianten im Vergleich

Entwicklung der R-CNN-Idee

- **R-CNN**: Regionen einzeln.
- **Fast R-CNN**: Feature Map.
- **Faster R-CNN**: RPN-Vorschläge.

Projektvarianten

- **ResNet50-FPN**: Final.
- **MobileNetV3-FPN**: Guard.
- Torchvision: Head ersetzt.
- Two-Stage: langsamer.

Modelltypen im Projekt

Modell	Familie	Anchor	Prinzip	Stärke
Faster R-CNN [3]	Two-Stage	basiert	Vorschläge	Boxen
RetinaNet [1]	One-Stage	basiert	direkt	Focal
FCOS [4]	One-Stage	frei	direkt	Recall
YOLOv8m [6]	One-Stage	implizit	direkt	Video

Training: Optimizer und Scheduler

Optimizer: Gewichte aktualisieren

- **SGD**: Mini-Batch-Schritte
- **AdamW**: adaptive Schritte
- **Momentum**: Einfluss vom Vorschritt
- **Weight Decay**: Gewichte bremsen

Scheduler: Lernrate steuern

- Start: grobe Schritte.
- Ende: feine Schritte.
- Projekt: AdamW + Cosine.
- Legacy: SGD + StepLR.

Trainingsdaten und Laufgroessen

Lauf	Zweck	Trainingsbilder	Epochen	Batch
Red20-Smoke	Vorauswahl	ca. 644	1	2
Red6-Final	Hauptvergleich	2.147	10	2
RCNN-Guard	Thermiktest	644	1	2

Trainingsablauf und Ressourcen

Ablauf pro Training

1. Labels konvertieren.
2. Head ersetzen.
3. Loss berechnen.
4. Checkpoint speichern.

Finale Trainingsläufe

Modell	Zeit	Hinweis
YOLO	16,1m	50 MB
FCOS	58m	123 MB
FRCNN	42m	158 MB

Faster R-CNN: Effizienz und Grenzen

105-Grad-/8h-Lauf

- 105 °C Limit.
- 8 h Limit.
- **MobileNetV3-FPN.**
- batch=2, 256/384.
- Red20/1 ausgeführt.

Gemessene Grenzen

- ResNet: langsam.
- Mobile: Guard-Abbruch.
- Final: 12:56 min.
- Max: 88 °C.
- Recall: 0,365.

Evaluation

Metriken

- Recall: Datenschutz
- Treffer: Menge erkannter Gesichter bei IoU
- Precision: Threshold abhängig
- ms/Bild: Inferenzzeit
- Gleiche IoU/Confidence


Vergleich aller Modelle: Red20-Vorauswahl

Modell	GT-Faces	Treffer	Recall	ms/Bild	Rolle nach Vorauswahl
FCOS R50 ep1	3.443	1.884	0,547	36,2	Recall
FRCNN R50 ep1	3.443	1.714	0,498	51,4	RCNN
YOLOv8m ep1	3.443	1.399	0,406	43,7	Pipeline
RetinaNet ep1	3.443	1.125	0,327	35,0	verworfen

Finaler Vergleich nach Red6/10-Training

Modell	GT-Faces	Treffer	Recall	ms/Bild	Interpretation
FCOS R50 ep10	5.015	3.375	0,673	34,9	Recall
YOLOv8m ep10	5.015	2.283	0,455	14,6	Pipeline
FRCNN R50 ep10	5.015	3.025	0,603	49,2	Two-Stage

Loss-Entwicklung




Roh-Loss ist je Modell anders skaliert; normalisierte Kurven zeigen den Trend.

Validierungsdurchlauf

Einstellung	Red20	Red6/10
Validierungsbilder	300	500
GT-Faces	3.443	5.015
IoU-Schwelle	0,4	0,4
Confidence	0,25	0,25

Recall-Entwicklung



Recall-Entwicklung: Vorauswahl zu Finalvergleich



Threshold-Sweep

Threshold-Sweep im Finalvergleich


—●— FCOS —●— Faster R-CNN



Hoeherer Threshold: weniger Boxen, meist hoehere Precision und niedrigerer Recall

Threshold 0,25: FCOS ist Recall-Sieger.


Latenz im Finalvergleich



Gewinner und Übergabe


- FCOS: Recall.
- YOLO: Pipeline.
- RCNN: Two-Stage.

YOLO-Trainingsartefakte



Faster R-CNN: Loss bis ep30


Faster R-CNN: Loss bis Full-Dataset-Training



Trainingsphase	Bilder	Zeit	Energie (GPU, ca.)
Red6 ep11–25	2.147	50,0 min	0,08 kWh
Full ep26–30	12.880	74,9 min	0,12 kWh

Energie geschätzt mit 100 W GPU-Mittelwert aus Faster-R-CNN-s640-Thermal-Benchmark.

Faster R-CNN: Recall bis ep30




Modell	Eval-Bilder	GT-Faces	Recall	Inferenzzeit
Red6 ep25	500	5.015	60,1%	49,5 ms/Bild
Full ep30	500	5.015	66,6%	49,2 ms/Bild

Evaluation: IoU 0,4, Confidence 0,25; reine Inferenz ca. 24,7 s pro Modell.

Video-Anonymisierung


Video-Pipeline

1. Video laden.
2. Deinterlacen.
3. Faces detektieren.
4. Oval blurren.
5. Export schreiben.




Selektives Blurring

Preview mit IDs



Selektiver Blur



IDs/Ränge setzen; visuell prüfen.

Ergebnisvideo und Blur-Qualität

- Gaussian: weich.
- Pixelate: sichtbar.
- Recall bestimmt Qualität.
- Video prüfen.

Demo-Idee: Videovergleich

- Früh: Originalvideo zeigen.
- Nach Evaluation: Modell-Blurs zeigen.
- Vergleich: YOLO, FCOS, RCNN.
- Fokus: verpasste Gesichter.

Ausblick: Modelle weiterentwickeln

- **Mehr Domänendaten:** eigene Video-Frames, Innenräume, schlechte Beleuchtung und kleine Gesichter nachtrainieren.
- **Active Learning:** nur schwierige Fehlfälle manuell labeln: verpasste Gesichter, Profile, verdeckte Gesichter.
- **Temporal stabilisieren:** Detektion mit Tracking kombinieren, damit Gesichter zwischen Frames nicht flackern.
- **Threshold kalibrieren:** je Anwendung anderer Punkt zwischen Datenschutz-Recall und Fehlalarmrate.
- **Deployment optimieren:** Export nach ONNX/TensorRT, Quantisierung und Benchmark auf Zielhardware.
- **Privacy-QA:** automatische Stichproben nach dem Blur, besonders bei kleinen und unscharfen Gesichtern.

Ausblick: mögliche Anwendungen

Datenschutz-Pipeline

- Video-Anonymisierung vor Veröffentlichung
- Dashcam-, Bodycam- und Eventmaterial
- Forschungsdatensätze mit weniger Personenbezug

Produktive Erweiterungen

- Vorblur für Medienproduktion
- Label-Assistenz für neue Trainingsdaten
- Datenschutzfilter für Kameraanalyse

Starkes Modell	Nächster Schritt
Red6 ep25	guter Spezialist, weiter mit schwierigen Fehlfällen nachtrainieren
Full ep30	bessere Generalisierung, für produktive Pipeline zuerst kalibrieren

Kerngedanke: Hoher Recall ist für Datenschutz wichtiger als perfekte Boxen.

Fazit: Pipeline-Entscheidung

- Red6/10: faire Basis.
- FCOS: bester Recall.
- YOLO: schnellste Pipeline.
- RCNN: Two-Stage-Vergleich.

Quellen

- [1] Tsung-Yi Lin et al. "Focal Loss for Dense Object Detection". In: *arXiv preprint arXiv:1708.02002* (2017).
- [2] mksaad. *WIDER FACE: A Face Detection Benchmark Dataset on Kaggle*. Kaggle dataset: <https://www.kaggle.com/datasets/mksaad/wider-face-a-face-detection-benchmark>. Kaggle. 2020. URL: <https://www.kaggle.com/datasets/mksaad/wider-face-a-face-detection-benchmark> (visited on 06/25/2026).
- [3] Shaoqing Ren et al. "Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks". In: *arXiv preprint arXiv:1506.01497* (2015).
- [4] Zhi Tian et al. "FCOS: Fully Convolutional One-Stage Object Detection". In: *arXiv preprint arXiv:1904.01355* (2019).
- [5] Shuo Yang et al. "WIDER FACE: A Face Detection Benchmark". In: *arXiv preprint arXiv:1511.06523* (2015).
- [6] Muhammad Yaseen. "What is YOLOv8: An In-Depth Exploration of the Internal Features of the Next-Generation Object Detector". In: *arXiv preprint arXiv:2408.15857* (2024).